



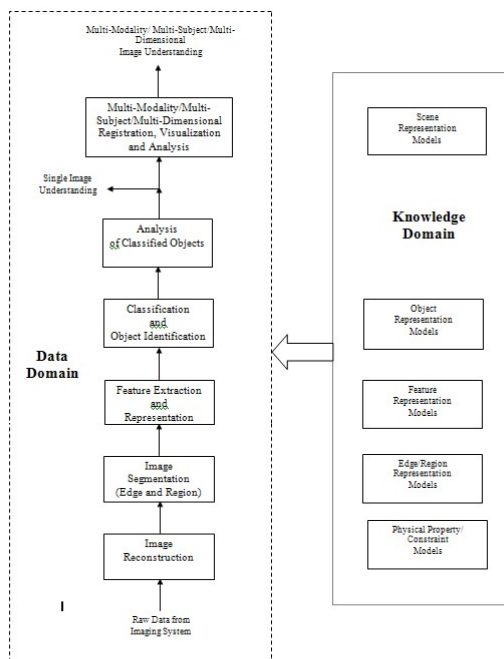
Representação e Análise de Imagem

V Vasconcelos

Processamento de Imagem Médica

1

Estrutura hierárquica de análise de imagem médica [1].





Extracção de Características e Representação

Após a segmentação da imagem, **características específicas** e **propriedades** representativas da região segmentada podem ser extraídas para compreender os objectos e os classificar.

Características usadas na representação de regiões:

- Estatísticas (*Statistical Pixel-Level*)
- Forma
- Textura



Estatísticas de 1ª ordem

Fornecem informação quantitativa acerca dos píxeis da região segmentada. Podem incluir:

Histograma Normalizado

$$h(k) = \frac{n_k}{M \times N}$$

Onde $h(k)$ e n_k são, respectivamente, a probabilidade e o nº de ocorrências do nível de cinzento k , na região e M e N a dimensão da região.

Média dos píxeis da imagem é dada por

$$\mu = \sum_{k=0}^{L-1} kh(k)$$

onde L é o número total de níveis de cinzento da imagem.



Estatísticas de 1ª ordem

Momentos Centrais de Ordem n

$$\mu_n = \sum_{k=0}^{L-1} (k - \mu)^n h(k)$$

Sendo para

$n=2 \rightarrow \mu_2$ é a variância

$n=3 \rightarrow$ simetria (skewness) medida de não centralidade


$$SKE = \frac{1}{\sigma^3} \sum_{i=0}^{L-1} h(i)(i - \mu)^3$$



Estatísticas de 1ª ordem

simetria (skewness) medida de não centralidade

$$SKE = \frac{1}{\sigma^3} \sum_{i=0}^{L-1} h(i)(i - \mu)^3$$





Estatísticas de 1ª ordem

Momentos Centrais de Ordem n


$n=4 \rightarrow$ curtose (*kurtosis*) - medida de achatamento do histograma relativamente à distribuição normal

$$CUR = \frac{1}{\sigma^4} \sum_{i=0}^{L-1} h(i) (i - \mu)^4 - 3$$

Curva a verde \rightarrow curtose > 0 ; leptocúrtica

Curva a azul \rightarrow curtose $= 0$; mesocúrtica

Curva a verde \rightarrow curtose < 0 ; platicúrtica



Estatísticas de 1ª ordem

Energia ou uniformidade

Medida de não uniformidade

$$Energia = \sum_{k=0}^{L-1} h(k)^2$$

$$A =$$

1	1	1
1	1	1
1	1	1

$$Energia = 1$$

$$B =$$

0	1	2	3
4	5	6	7
8	9	10	11

$$Energia = 0.069$$



Entropia

Estatísticas de 1ª ordem

$$Entropia = - \sum_{k=0}^{L-1} h(k) \log_2 (h(k))$$

Mede a desordem ou aleatoriedade de um sistema.



Medida de informação representada pela distribuição dos valores do nível de cinzento na região.

No caso da imagem:



- * Se o histograma da imagem se encontrar uniformemente distribuído ao longo dos níveis de cinzento, a **entropia é máxima**.
- * Uma imagem a preto e branco (apenas dois estados estão ocupados) a **entropia é baixa**.
- * Todos os píxeis tiverem o mesmo valor **entropia=log2(1)=0**.



Entropia Exemplo




Entropia: 6.01 bits/pixel




Entropia : 4.72 bits/pixel



Entropia Exemplo



Valor da Entropia: 7.1073 bits/pixel



Valor da Entropia: 0.9694 bits/pixel



Forma

São várias as características que podem ser usadas para representar a forma de uma região segmentada, que é basicamente a distribuição espacial dos píxeis da fronteira.

Área (A) – nº de píxeis do objecto


Perímetro (P) - nº de píxeis na fronteira do objecto

Circularidade (C) – $C = \frac{4\pi A}{P^2}$

Compacidade (Cp) – $C_p = \frac{P^2}{A}$

Maior Eixo - GE

Menor Eixo - HF





Função regionprops

Shape Measurements

'Area'	'EulerNumber'	'Orientation'
'BoundingBox'	'Extent'	'Perimeter'
'Centroid'	'Extrema'	'PixelIdxList'
'ConvexArea'	'FilledArea'	'PixelList'
'ConvexHull'	'FilledImage'	'Solidity'
'ConvexImage'	'Image'	'SubarrayIdx'
'Eccentricity'	'MajorAxisLength'	
'EquivDiameter'	'MinorAxisLength'	

Pixel Value Measurements

'MaxIntensity'	'MinIntensity'	'WeightedCentroid'
'MeanIntensity'	'PixelValues'	




Função regionprops – Aplicação a Lesões Dermoscópicas

original

original gray

Imagem Binária





Area	5101	5101
Centroid	[58.1553,65.8512]	58.1553
BoundingBox	[19.5000,19.5000,78,9...	19.5000
SubarrayIdx	<1x2 cell>	
MajorAxisLength	91.4175	91.4175
MinorAxisLength	71.2770	71.2770
Eccentricity	0.6262	0.6262
Orientation	63.3144	63.3144
ConvexHull	<80x2 double>	19.5000
ConvexImage	<91x78 logical>	
ConvexArea	5245	5245
Image	<91x78 logical>	
FilledImage	<91x78 logical>	
FilledArea	5101	5101
EulerNumber	1	1
Extrema	<8x2 double>	19.5000
EquivDiameter	80.5903	80.5903
Solidity	0.9725	0.9725
Extent	0.7187	0.7187
PixelIdxList	<5101x1 double>	2458
PixelList	<5101x2 double>	20
Perimeter	279.5635	279.5635




Função regionprops – Aplicação Contagem de Células

BoundingBox



Função regionprops – Objectos com Forma Redonda

Eccentricity






Codificação de Contornos: *Chain Code*

Através de um conjunto de primitivas são codificadas as diferentes direcções.

Se considerarmos a **vizinhança-8** as orientações são representadas de 0-7.

3	2	1
4	x_c	0
5	6	7



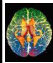
Codificação de Contornos: *Chain Code*

Para que um contorno possa ser codificado através dos **códigos de orientação** o contorno tem de ser aproximado por uma lista de segmentos.

Para obter o conjunto de segmentos que caracterizem o contorno, este tem de ser **discreto**.

Por exemplo, no método **"divide-and-conquer"**, os pontos com uma variação grande na direcção do **gradiente** são escolhidos para potenciais vértices. Se o segmento de recta que une dois vértices **não respeita** um critério de **"máximo-desvio"**, o segmento é sub-dividido.

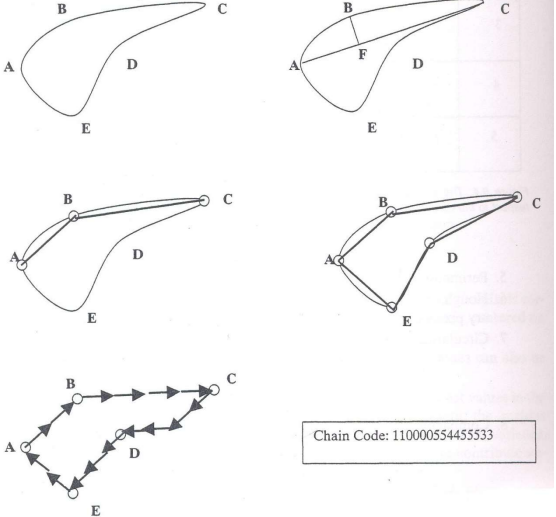
O critério de "máximo-desvio" é baseado na distância na perpendicular entre dois vértices do contorno original, **B-F**




218 IMAGE REPRESENTATION AND ANALYSIS

SE $BF > \text{Limiar}$
ENTÃO

Dividir **AC** no ponto onde o desvio é máximo



Chain Code: 110000554455533



Características de Textura

A textura é uma propriedade espacial muito importante que pode ser utilizada na segmentação de regiões, assim como na sua descrição. Existem três aproximações principais na descrição da textura:

- **Estatística** - baseiam-se na distribuição dos valores de nível de cinzento da imagem.
- Estrutural – baseiam-se no arranjo de primitivas pré-estabelecidas.
- Espectral – baseiam-se em métodos de análise espectral, tais como, transformada de Fourier e wavelet.




Aproximação Estatística Matriz de co-ocorrência

A matriz de co-ocorrência explora a distribuição dos níveis de cinzento, numa determinada vizinhança.

Também se pode calcular a matriz de coocorrência considerando os dois sentidos. Por exemplo, para **d=1**; **ang=0°**, a matriz **G** é calculada da seguinte forma

graycomatrix



Alguns Descritores obtidos da Matriz de Co-ocorrência

Descriptor	Explanation	Formula
Maximum probability	Measures the strongest response of G . The range of values is [0, 1].	$\max_{i,j}(p_{ij})$
Correlation	A measure of how correlated a pixel is to its neighbor over the entire image. Range of values is 1 to -1, corresponding to perfect positive and perfect negative correlations. This measure is not defined if either standard deviation is zero.	$\frac{\sum_{i=1}^K \sum_{j=1}^K (i - m_r)(j - m_c) p_{ij}}{\sigma_r \sigma_c}$ $\sigma_r \neq 0; \sigma_c \neq 0$
Contrast	A measure of intensity contrast between a pixel and its neighbor over the entire image. The range of values is 0 (when G is constant) to $(K - 1)^2$.	$\sum_{i=1}^K \sum_{j=1}^K (i - j)^2 p_{ij}$
Uniformity (discrete Energy)	A measure of uniformity in the range [0, 1]. Uniformity is 1 for a constant image.	$\sum_{i=1}^K \sum_{j=1}^K p_{ij}^2$
Homogeneity	Measures the spatial closeness of the distribution of elements in G to the diagonal. The range of values is [0, 1], with the maximum being achieved when G is a diagonal matrix.	$\frac{\sum_{i=1}^K \sum_{j=1}^K p_{ij}}{\sum_{i=1}^K \sum_{j=1}^K 1 + i - j }$
Entropy	Measures the randomness of the elements of G . The entropy is 0 when all p_{ij} 's are 0 and is maximum when all p_{ij} 's are equal. The maximum value is $2 \log_2 K$. (See Eq. (11.3-9) regarding entropy).	$-\sum_{i=1}^K \sum_{j=1}^K p_{ij} \log_2 p_{ij}$

TABLE 11.3


Descriptors used for characterizing co-occurrence matrices of size $K \times K$. The term p_{ij} is the ij th term of **G** divided by the sum of the elements of **G**.

graycoprops
- Matlab

p_{ij} é a
Matriz P normalizada



Aproximação Estatística Matriz de co-ocorrência Exemplo



a
b
c


FIGURE 11.30
Images whose
pixels have
(a) random,
(b) periodic, and
(c) mixed texture
patterns. Each
image is of size
 263×800 pixels.



Aproximação Estatística Matriz de co-ocorrência Exemplo

Descritores obtidos a partir da matriz de co-ocorrência, correspondente a cada uma das imagens anteriores.

Normalized Co-occurrence Matrix	Descriptor					
	Max Probability	Correlation	Contrast	Uniformity	Homogeneity	Entropy
G_1/n_1	0.00006	-0.0005	10838	0.00002	0.0366	15.75
G_2/n_2	0.01500	0.9650	570	0.01230	0.0824	6.43
G_3/n_3	0.06860	0.8798	1356	0.00480	0.2048	13.58





Aproximação Estatística Matriz de Primitivas de Comprimento

Baseia-se no cálculo de primitivas de comprimento (*run-length primitives*), que são conjuntos de píxeis consecutivos com o mesmo nível de cinzento, numa dada direcção.

		Run Length					
		1	2	3	4	5	
Image	Gray Levels	1	1	2	2	2	
		1	1	2	2	2	
		1	3	3	3	3	
		3	3	4	4	4	
		3	3	4	4	4	
		4	0	0	2	0	0

Matriz
 $M(a,r|\theta); \theta=0^\circ$



Aproximação Estatística Matriz de Primitivas de Comprimento

A partir da matriz de primitivas de comprimento podem ser calculados descritores de textura.

Feature	Formula
1. Short Run Emphasis	$SRE = \frac{1}{n_r} \sum_{a=1}^L \sum_{r=1}^{M^*} \frac{M(a,r)}{r^2}$ <p>n_r is total number of primitives</p>
2. Long Run Emphasis	$LRE = \frac{1}{n_r} \sum_{a=1}^L \sum_{r=1}^{M^*} M(a,r) r^2$
3. Gray Level Non-Uniformity	$GLNU = \frac{1}{n_r} \sum_{a=1}^L \left(\sum_{r=1}^{M^*} M(a,r) \right)^2$
4. Run Length Non-Uniformity	$RLNU = \frac{1}{n_r} \sum_{r=1}^{M^*} \left(\sum_{a=1}^L M(a,r) \right)^2$
5. Run Percentage	$RPC = \frac{n_r}{n_p}$ <p>n_p is total number of pixels</p>



Diagnóstico Assistido por Computador (Computer-Aided Diagnosis)

Motivação:

- Elevado volume de imagens gerados pelos actuais meios imagiológicos de auxílio ao diagnóstico
- Formato digital das imagens médicas
- Uniformização do armazenamento das imagens



Sistemas de Diagnóstico Assistido por Computador



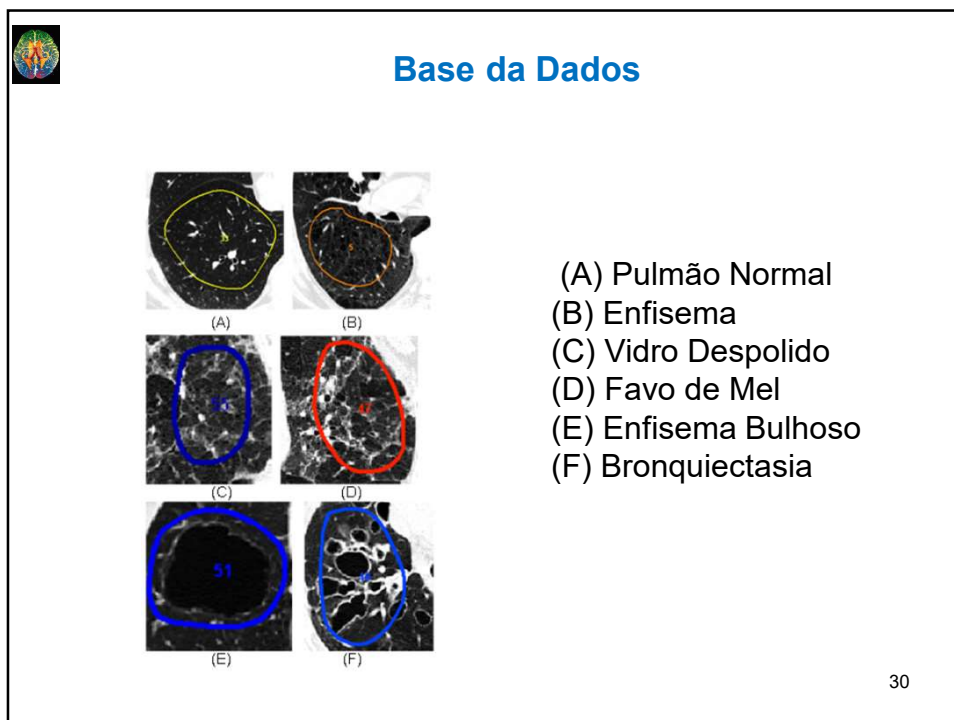
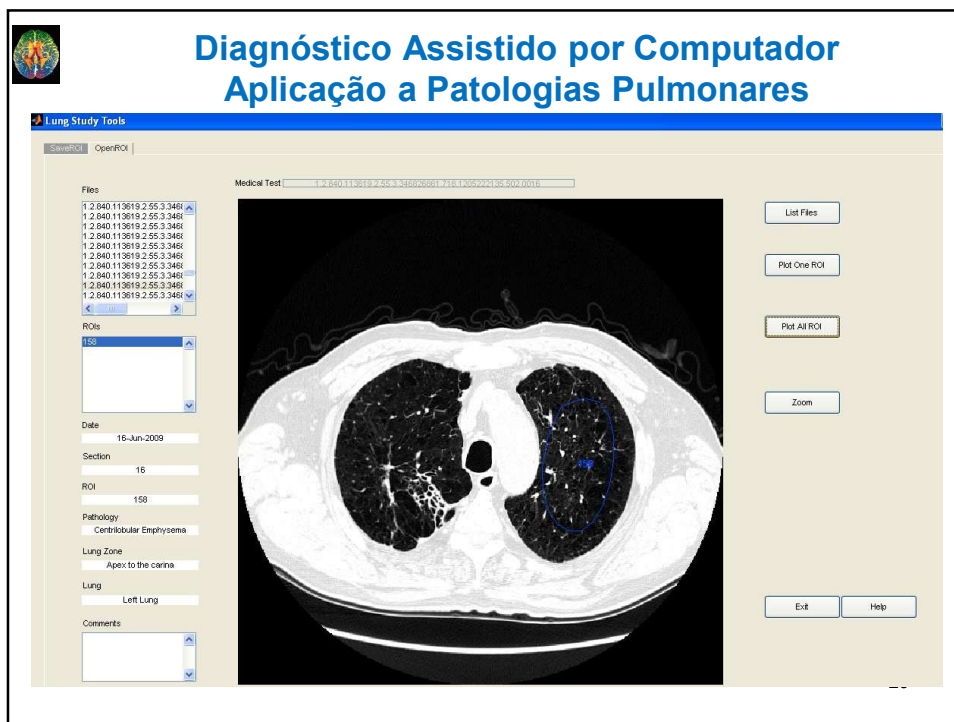
Segunda Opinião que auxilia o médico na elaboração do diagnóstico

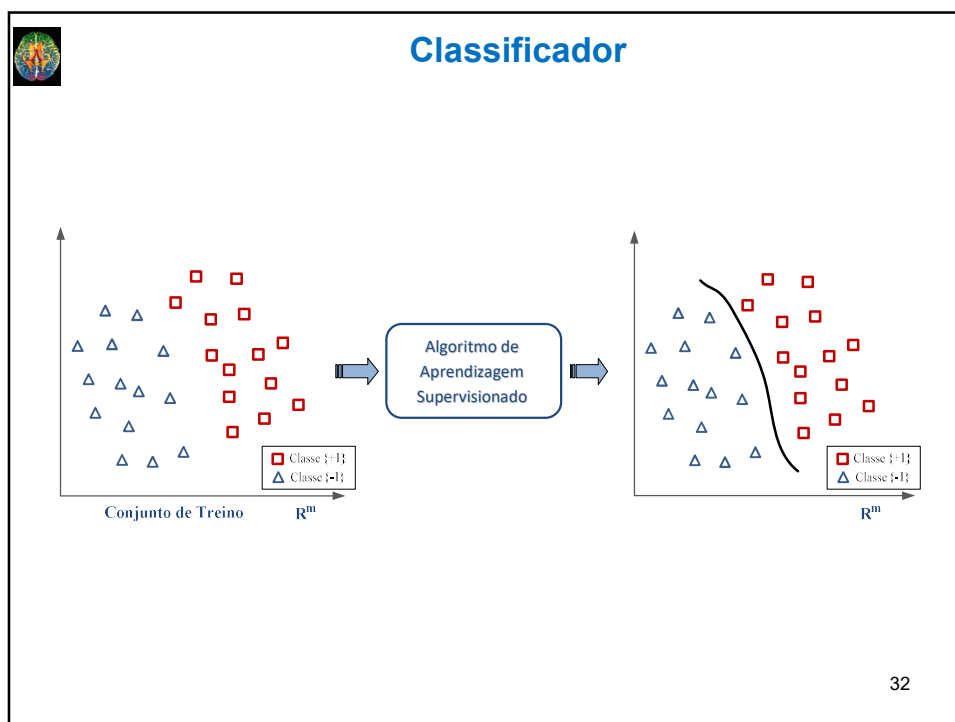
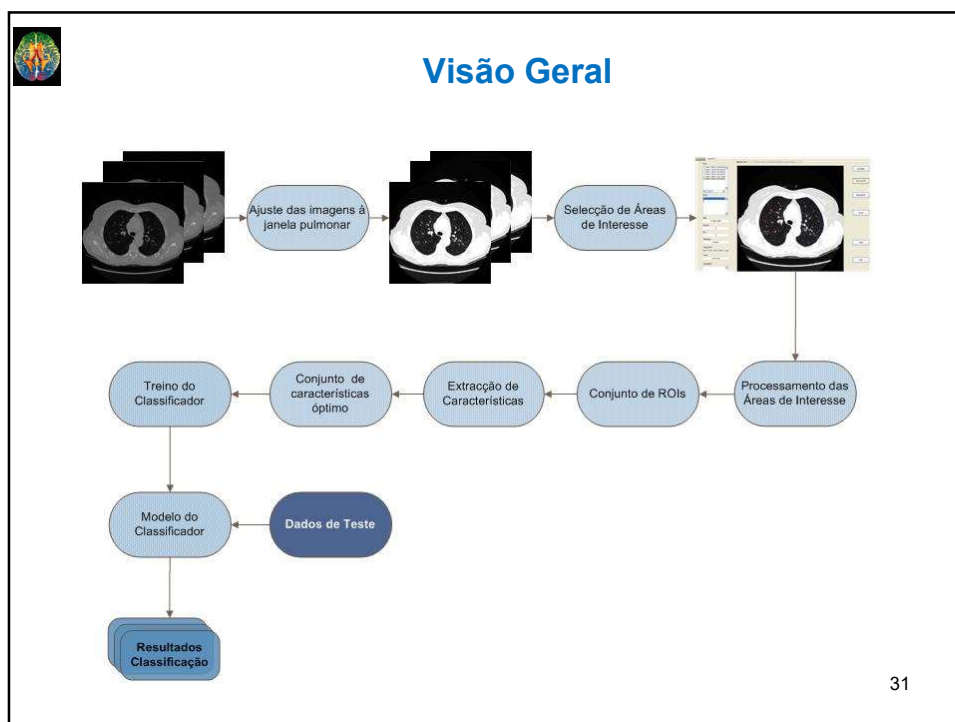




Diagnóstico Assistido por Computador Aplicação a Patologias Pulmonares

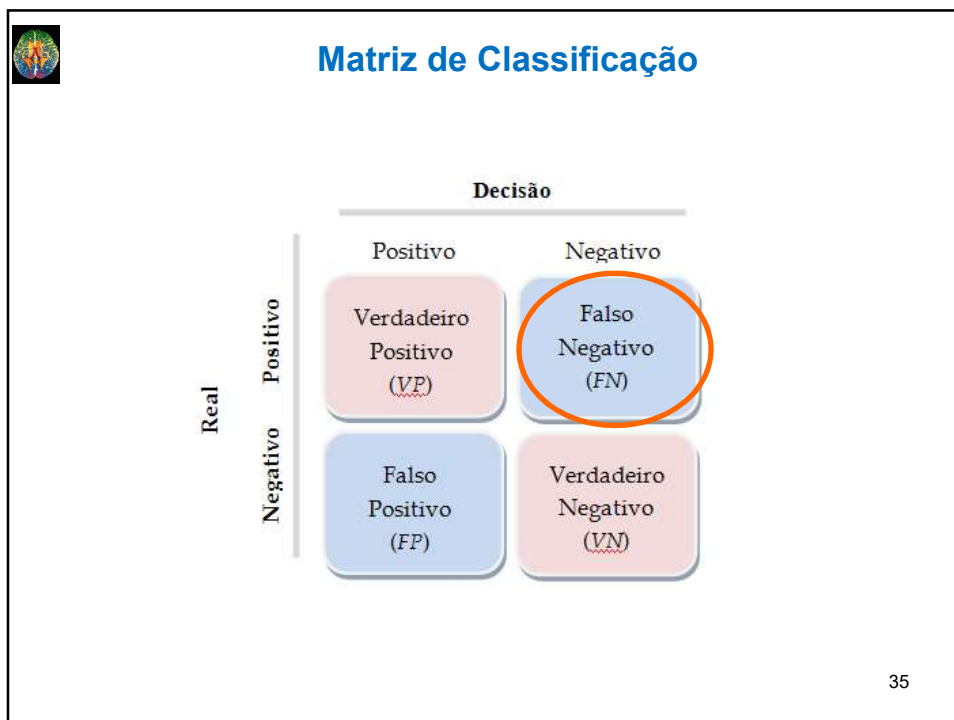


28









Avaliação dos Resultados

Accuracy:

$$Accuracy = \frac{VP + VN}{VP + VN + FP + FN}$$

Sensibilidade:

$$Sensibilidade = \frac{VP}{VP + FN}$$

Especificidade:

$$Especificidade = \frac{VN}{VN + FP}$$

36



Referências Bibliográficas

1. A. P. Dhawan, Medical Image Analysis, Wiley-IEEE Press, 2003.
2. R. C. Gonzalez, R. E. Woods, Digital image processing, Pearson/Prentice Hall, Third Edition, 2008.
3. G. Dougherty, Digital Image Processing for Medical Applications, Cambridge University Press, 2009.
4. L. G. Shapiro, G. C. Stockman, Computer Vision, Prentice Hall, 2001.
5. K. Najarian, R. Splinter, Biomedical Signal and Image Processing, CRC Press, 2005.

Nota: As imagens que constam dos diapositivos são retiradas das referências bibliográficas.